




Лекция. LLM Продукты

Дмитрий Меркушов
16.04.2025



План лекции

1

Продуктовый
подход

2

Планирование
ресурса

3

Техническая
адаптация

4

Вредные
советы

Совет

Если вы стремглав решили
LLM-ку свою сделать,
Посчитали, сколько стоит -
Приходите к СТО,

Говорите, что вам надо:
Тыщи карт, пятьсот разработов.
Всё дадут и даже больше,
Очень просто и легко.



Типизация Продуктов



Какими продуктами/фичами пользуетесь вы

Типизация GenAI Продуктов



Типизация GenAI Продуктов

- 1 API / ChatUI
- 2 Новый функционал в существующих продуктах
- 3 Новые продукты
- 4 Copilots / Assistants
- 5 OS
- 0 Модель itself !

Все это Ассистенты

● ИИ-ассистенты

Чатботы общего и
специального назначения

ANTHROPIC

Gemini

ChatGPT

Meta AI

casetext
Smarter legal research

grammarly

● Создание контента

Генерация ИИ контента из
текстового запроса

OpenAI
Sora

FREEPIK

Notion

miro

ElevenLabs

● Редактирование контента

Работа с файлами,
улучшение и оптимизация

Adobe

CapCut

removebg

ZEROGPT

wondershare

● ИИ-компаньоны

NSFW-боты*,
развлекательные чат-боты

JANITOR AI

SPICYCHAT.AI

candy.ai

● ИИ-EdTech


Помощники в научных и
учебных запросах

Course Hero


Gauthmath

Semantic Scholar

Top Gen AI Consumer Mobile Apps: Companies Per Category



Top Gen AI Consumer Web Products: Companies Per Category




Типизация Продуктов



↑ Memories создает видеоролик из фотографий на основании текстового описания и ключевых слов



← OpenAI запустила AI-агента Operator, который самостоятельно выполняет задачи в браузере вместо пользователя




← Пользователи могут переписывать текст, проверять данные, находить источники в любом месте — в редакторе, браузере.

Это только начало




Глобальная оценка GenAI (до Stargate)



А у нас в квартире газ, а у вас

США: к 2030 году объем рынка GenAI прогнозируется на уровне \$115,2 млрд. Основные сегменты — реклама, медиа и игры, при этом ожидается, что рекламный сектор станет ключевым драйвером роста. США сохраняют лидерство благодаря технологическим инновациям и масштабным венчурным инвестициям.

Азиатско-Тихоокеанский регион демонстрирует стремительный рост внедрения GenAI — к 2030 году рынок ожидаемо достигнет \$52 млрд (Китай — \$31 млрд, Япония — \$13 млрд, Южная Корея — \$7 млрд). Развитие обусловлено мощной технологической инфраструктурой и активными инвестициями в исследования.



Европа: к 2030 году рынок GenAI прогнозируется на уровне \$108 млрд. Ключевые сегменты — здравоохранение, автомобилестроение и производство, при этом наибольший рост ожидается в сфере медицины благодаря развитию AI-решений в диагностике и лечении.

К 2030 году объем рынка GenAI в России прогнозируется на уровне \$4,15 млрд, со среднегодовым ростом 25%. Технология набирает популярность как среди бизнеса, так и среди частных пользователей.

Цель



Зачем LLM

1


Вырасти
технологически

2

Оптимизация

3

Новые
фичи/
продукты



Зачем LLM. Технологически

- Новые направления экспертизы: NLP, AI-тренеры, PR/Маркетинг
- Качественный буст ML-инфраструктуры
- Подготовка к next big thing

Зачем LLM. Оптимизация

- Делать больше (KPI на число строк)
- Делать быстрее (KPI на TimeToMarket)
- Делать меньшим ресурсом (KPI на перераспределение)

Зачем LLM. Новые фичи / продукты

- Удовлетворить созданный спрос
 - (Alexa -> Алиса -> Маруся)
- Создать новый спрос
 - Генеративный поиск

Что будем делать



Выбор сценария

1


LLM-мышление

2


Хеджирование

3

Оценка
эффектив
ности



Выбор сценария. LLM Мышление



Быстрая проверка гипотез

- FewShot как аналог SFT
- Чат-бот/API для прототипа
- С оглядкой на **сенситивность**
- Какое качество **минимально ОК**

Выбор сценария. Хеджирование

ИИ в Почте

Создал(а) [имя], [фамилия] [инициалы], отредактировал(а) [имя], [фамилия] [инициалы] 2025-01-21

Стратегия	Исследования	Артефакты от продуктов	Брейнштормы	Аналитика
				
Сюда мы вносим все, что делали для нас стратеги 1. Подсчёт БигБетов ИИ	Сюда вносим все качественные и количественные	1. Стратегия СуперАпп от Толи (нояб 2024)	Сюда вносим все брейнштормы на любые темы	1. Комментарии из CSAT опроса по GPT

Инфраструктура /
КОСТЫ



Инфра

1


Pretrain

2

GPU

3

SFT/Align



Инфраструктура для претрейна

- Карты, сеть
- Парсеры / фильтры данных
- Дорого (₽ bn) / долго (год с нуля) / необходимо для ряда сценариев (code-copilot)

Cloud Gpu

Модель GPU NVIDIA® Tesla®

A100 80GB

Количество карт, шт. ⓘ

4

Операционная система

AlmaLinux

CPU, шт. ⓘ

128

RAM, ГБ

768

Тарифный план

Месячный

Годовой план: период оплаты составляет 1 месяц, минимальное использование — 1 год

Месячный план: период оплаты и минимальное использование — 1 месяц

Часовой план: период оплаты и минимальное использование — 1 час

Жесткий диск, ГБ

10

Тип диска 1 ⓘ

HDD

[+ Добавить еще один диск](#)

Итоговый расчет ⓘ

Кол-во сервисов в данной конфигурации

1

Цена за месяц ⓘ

950 840 ₽

Цена за день ⓘ

31 694,67 ₽

Тестировать

- Гомогенность
- Сложнее для обучения (сеть)

Источник

Model	Parameters (B)	VRAM Requirement (GB)	Recommended GPU	VRAM Requirement (GB) (4-bit)	Recommended GPU
DeepSeek-R1-Zero	671B	~1,543 GB	Multi-GPU setup (e.g., NVIDIA A100 80GB x16)	~436 GB	Multi-GPU setup (e.g., NVIDIA A100 80GB x6)
DeepSeek-R1	671B	~1,543 GB	Multi-GPU setup (e.g., NVIDIA A100 80GB x16)	~436 GB	Multi-GPU setup (e.g., NVIDIA A100 80GB x6)
DeepSeek-R1-Distill-Qwen-1.5B	1.5B	~3.9 GB	NVIDIA RTX 3060 12GB or higher	~1 GB	NVIDIA RTX 3050 8GB or higher
DeepSeek-R1-Distill-Qwen-7B	7B	~18 GB	NVIDIA RTX 4090 24GB or higher	~4.5 GB	NVIDIA RTX 3060 12GB or higher
DeepSeek-R1-Distill-Llama-8B	8B	~21 GB	NVIDIA RTX 4090 24GB or higher	~5 GB	NVIDIA RTX 3060 12GB or higher
DeepSeek-R1-Distill-Qwen-14B	14B	~36 GB	Multi-GPU setup (e.g., NVIDIA RTX 4090 x2)	~9 GB	NVIDIA RTX 4080 16GB or higher
DeepSeek-R1-Distill-Qwen-32B	32B	~82 GB	Multi-GPU setup (e.g., NVIDIA RTX 4090 x4)	~21GB	NVIDIA RTX 4090 24GB or higher
DeepSeek-R1-Distill-Llama-70B	70B	~181 GB	Multi-GPU setup (e.g., NVIDIA A100 80GB x3)	~46 GB	Multi-GPU setup (e.g. NVIDIA RTX 4090 24GB x2)

Что делать самим



Сами с усами

1

Pretrain

2

Prompting

3

SFT/Align

4

Данные



И ТАК
БОНДЕТ!

Свои данные

- AI-тренеры
- Stuff / коллеги - вместо AI-тренеров
- Пользователи - лайки и сценарии использования
- API чаще нельзя


Project Management



Контролируем темп разработки

Время - партнер

- Растет качество OpenSource, падает размер
- Появляется опыт коллег (в тч неуспешный)
- LLM для бедных Edge
 - Оптимизации / Лоры / Кванты
 - RLHF: PPO -> DPO -> SimPO -> ...
- Но! новые рынки быстро насыщаются



Контролируем риски

Время - враг


- Затерли чекпоинт - минус месяц
- Пользователи плохо онбординруются
- Лицензионные проволочки для OpenSource



Контролируем риски

Технические

- Этика протекает
 - Свой претрейн не умеет в этику
 - PR риск - этичность вииральна
- Галлюцинации неистребимы
 - можно ограничивать механиками в продукте



Подытожим



Чеклист

- ✓ Что хотим от LLM
 - ✓ Готовы к отложенному value
 - ✓ Расширили воронку сценариев
 - ✓ Проверили качество на доступных моделях
 - ✓ Оценили сенситивность данных для сценариев
 - ✓ Смоделировали дешевые эксперименты
 - ✓ Реализовали контур фидбека и быстрофиксов
 - ✓ Инвестировали в основные риски
 - ✓ Сделали глубокий вдох
-
- ~~✓ Открыли найм LLM суперзвезд~~
 - ✓ Вырастили своих NLP-разработчиков в LLM-суперзвезд



Бонус

Вредные LLM-советы

Если вы стремглав решили
LLM-ку свою сделать,
Посчитали, сколько стоит -
Приходите к СТО,

Говорите, что вам надо:
Тыщи карт, пятьсот разработов.
Всё дадут и даже больше,
Очень просто и легко.



Вопросы ?

